

**МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ**  
**ЖИТОМИРСЬКА ПОЛІТЕХНІКА**  
Кафедра ММСА

**ЛАБОРАТОРНА РОБОТА № 8**  
з дисципліни «Системи штучного інтелекту»

**НАВЧАННЯ НЕЙРОМЕРЕЖ.**  
**TENSORFLOW. KERAS**

Виконав: студент групи ВТ-23-2  
Камінський Олексій Дмитрович

Перевірив: \_\_\_\_\_

Житомир – 2026

**Репозиторій з кодом роботи:** <https://github.com/vt232kod-debug/systems-ai>

## Мета

Дослідити ресурси Keras і TensorFlow та застосувати TensorFlow для навчання лінійної регресії. Засобами TensorFlow реалізувати наведений у методичці код і дослідити структуру розрахункового алгоритму: генерацію даних, оголошення заглушок (placeholder) і змінних, побудову моделі та функції втрат, вибір оптимізатора і цикл навчання з міні-батчами.

Виконав: Камінський Олексій Дмитрович, група ВТ-23-2, варіант 3. Середовище: Python 3.14.6, TensorFlow 2.22.0-rc0, Keras 3.16 (бекенд — TensorFlow), NumPy 2.5.3, macOS (CPU).

Постановка задачі. Лінійна регресія — це фактично один нейрон, який отримує на вхід вектор  $x$  і видає число. На даних  $\{(x_1, y_1), \dots, (x_N, y_N)\}$  потрібно мінімізувати суму квадратів відхилень. Наближаємо функцію  $f = kx + b$  для істинних  $k = 2$  і  $b = 1$ ;  $k$  та  $b$  є параметрами, які навчаються.

Номер варіанта (3) використано як зерно генераторів випадкових чисел (`np.random.seed(3)`, `tf.set_random_seed(3)`), тому всі наведені нижче числа відтворюються при повторному запуску.

## Завдання 1. Дослівна реалізація коду методички (TensorFlow 1.x через `compat.v1`)

Код методички написаний під TensorFlow 1.x: він спирається на статичний граф обчислень (`tf.placeholder`), явну сесію (`tf.Session`), підстановку даних через `feed_dict` і оптимізатор `tf.train.GradientDescentOptimizer`. У встановленому TensorFlow 2.22 жодного з цих імен у кореновому просторі імен немає — TF2 працює в режимі негайного виконання (`eager`). Щоб довести, що відтворено саме алгоритм методички, а не «щось схоже», перший скрипт імпортує шар сумісності `tensorflow.compat.v1` і явно вимикає поведінку другої версії:

```
import tensorflow.compat.v1 as tf          # шар сумісності з TensorFlow 1.x
tf.disable_v2_behavior()                  # вимикаємо eager -> працює статичний граф
```

Далі структура розрахункового алгоритму повністю повторює 6 кроків методички.

**Крок 1 — генерація вхідних даних.** 1000 точок  $x$ , для кожної обчислюється «правильна відповідь»  $y = 2x + 1 + \varepsilon$ . Тут важлива суперечність: у ТЕКСТІ методички сказано, що точки розподілені рівномірно на інтервалі  $[0; 1]$ , а в КОДІ

методички стоїть `np.random.uniform(1, 10)`, тобто інтервал  $[1; 10]$ . Беремо код, бо саме він узгоджується з наведеним у методичці зразком виводу. Перевірено прямим обчисленням: у стані зі зразка методички ( $k = 0.8925$ ,  $b = 0.0988$ ) очікувана втрата на міні-батчі зі 100 точок дорівнює 6047 на інтервалі  $[1; 10]$  і лише 608 на інтервалі  $[0; 1]$ , тоді як методичка наводить 5962.16. Самі інтервали відрізняються за дисперсією  $x$  рівно у 81 раз (емпірично 6.5313 проти 0.0806, теоретично  $9^2 = 81$ ) і у 111 разів за  $E[x^2]$  (37.2723 проти 0.3356).

**Крок 2 — заглушки.** `tf.placeholder` з розмірністю (розмір міні-батча  $\times$  1) для  $X$  і для  $y$ .

**Крок 3 — змінні.**  $k$  ініціалізується стандартним нормальним розподілом,  $b$  — нулем.

**Крок 4 — модель і функція втрат.**  $y_{\text{pred}} = X \cdot k + b$ ,  $\text{loss} = \text{tf.reduce\_sum}((y - y_{\text{pred}}) ** 2)$ . Використано саме `tf.reduce_sum`, а не `numpy.sum`: сума має бути вузлом графа, інакше TensorFlow не зможе продиференціювати її й оптимізувати обчислення.

**Крок 5 — оптимізатор.** Стохастичний градієнтний спуск; `.minimize(loss)` повертає операцію, виконання якої оновлює всі змінні, від яких залежить `loss` (тобто  $k$  і  $b$ ). По  $X$  та  $y$  оптимізації не буде — це жорстко задані вхідні дані.

**Крок 6 — цикл навчання.** 20000 кроків; на кожному беремо випадкову підмножину з 100 індексів, формуємо міні-батч і передаємо його в `sess.run` через `feed_dict`.

```
n_samples, batch_size, num_steps = 1000, 100, 20000      # крок 1
X_data = np.random.uniform(1, 10, (n_samples, 1))        # 1000 точок x на [1; 10]
y_data = 2 * X_data + 1 + np.random.normal(0, 2, (n_samples, 1)) # y = 2x + 1 + шум

X = tf.placeholder(tf.float32, shape=(batch_size, 1))     # крок 2
y = tf.placeholder(tf.float32, shape=(batch_size, 1))

with tf.variable_scope('linear-regression'):              # крок 3
    k = tf.Variable(tf.random_normal((1, 1)), name='slope')
    b = tf.Variable(tf.zeros((1,)), name='bias')

y_pred = tf.matmul(X, k) + b                              # крок 4
loss = tf.reduce_sum((y - y_pred) ** 2)
optimizer = tf.train.GradientDescentOptimizer(LEARNING_RATE).minimize(loss) # крок 5

with tf.Session() as sess:                                # крок 6
    sess.run(tf.global_variables_initializer())
    for i in range(num_steps):
        indices = np.random.choice(n_samples, batch_size)
        X_batch, y_batch = X_data[indices], y_data[indices]
        _, loss_val, k_val, b_val = sess.run(
            [optimizer, loss, k, b],
```

```
feed_dict={X: X_batch, y: y_batch})
```

Темп навчання. У методичці `GradientDescentOptimizer()` викликано взагалі без аргументів, хоча `learning_rate` є обов'язковим. Оскільки `loss` — це СУМА по 100 елементах батча, її градієнт у 100 разів більший за градієнт середньої похибки, тому крок має бути малим. Для цих даних власні числа матриці одного кроку спуску дорівнюють 7620.18 та 34.28 (на одиницю `learning_rate`), тобто межа стійкості становить  $2/7620.18 = 2.62 \cdot 10^{-4}$ . Обрано `LEARNING_RATE = 1 \cdot 10^{-5}` — це 3.8 % від межі, спуск стійкий і при цьому достатньо швидкий. Оскільки темп навчання методичка не задає, її зразок виводу точно не відтворюється; окремий розділ «Звірка власного виводу зі зразком методички» нижче показує, який саме крок потрібен для збігу і чому обрано інший.

Нижче — СКОРОЧЕНИЙ витяг із консолі (скрипт друкує, як і методичка, рівно кожні 100 епох, тобто 200 рядків; додатково, понад методичку, друкуються перші 5 кроків):

```
Крок 1: 56663.01953125, k=-1.5840, b=0.0432
Крок 2: 52437.89062500, k=-1.3016, b=0.0848
Крок 5: 30832.37304688, k=-0.5939, b=0.1911
Епоха 100: 500.39248657, k=2.0511, b=0.5906
Епоха 500: 351.81582642, k=2.0363, b=0.6082
Епоха 4000: 472.98876953, k=2.0374, b=0.6894
Епоха 10000: 274.13494873, k=2.0240, b=0.7232
Епоха 16000: 365.94433594, k=2.0343, b=0.7249
Епоха 20000: 403.24114990, k=2.0370, b=0.7267
-----
TF1-compat: k = 2.0370, b = 0.7267, час навчання = 1.34 с
Аналітичний МНК (еталон): k = 2.0295, b = 0.7158
Істинні параметри генератора: k = 2.0000, b = 1.0000
Фінальна втрата на міні-батчі: 403.2411 (теоретична межа ~ batch*sigma^2 = 400)
Стартове значення k (випадкова ініціалізація): -1.8647
```




Рисунок 1 — хмара з 1000 точок, істинна пряма  $y = 2x + 1$  та пряма, навчена TF1-compat




Рисунок 2 — спадання функції втрат: зліва перші 300 епох, справа всі 20000 епох




Рисунок 3 — збіжність коефіцієнтів  $k$  та  $b$  по епохах

Два вікна на рисунках 2 і 3 потрібні тому, що з кроком друку 100 епох (як у методичці) основне спадання взагалі не видно: функція втрат падає з 56663 до  $\sim 500$  за перші  $\sim 60$  ітерацій, тобто повністю до першого ж друку. Тому історію в скрипті записуємо на кожному кроці, а друкуємо рівно кожні 100 епох, як вимагає методичка; у звіт із цих 200 рядків винесено лише скорочений витяг.

Розрахунковий алгоритм має два чітко розділені режими збіжності, що відповідають двом власним числам матриці кроку. «Швидкий» режим (власне число 7620) за  $\sim 60$  ітерацій виводить нахил  $k$  практично на оптимум. «Повільний» режим (власне число 34.3, у 222 рази менше) відповідає за зсув  $b$ , і саме він розтягує навчання на всі 20000 кроків:  $b$  повзе від 0.59 на 100-й епосі до 0.727 на 20000-й.

**Висновок:** код методички відтворено дослівно через `tensorflow.compat.v1`; усі шість кроків алгоритму працюють, функція втрат спадає з 56663 до  $\sim 403$ , що збігається з теоретичною межею  $\text{batch} \cdot \sigma^2 = 100 \cdot 2^2 = 400$ , а параметри сходяться до  $k = 2.0370$  і  $b = 0.7267$  — практично до аналітичного розв'язку МНК (2.0295 і 0.7158).

## Завдання 2. Сучасна реалізація того самого алгоритму на TensorFlow 2.x

Другий скрипт розв'язує рівно ту саму задачу — той самий генератор даних, те саме зерно 3, ті самі `n_samples = 1000`, `batch_size = 100`, `num_steps = 20000` і `learning_rate = 1 \cdot 10^{-5}` — але засобами «рідного» TF2. Концептуальні відмінності:

| Елемент        | TensorFlow 1.x (методичка)                  | TensorFlow 2.x              |
|----------------|---------------------------------------------|-----------------------------|
| Передача даних | <code>`tf.placeholder` + `feed_dict`</code> | звичайні аргументи функції  |
| Виконання      | статичний граф + <code>`tf.Session`</code>  | негайне (eager), граф через |

|               |                                                  |                                                      |
|---------------|--------------------------------------------------|------------------------------------------------------|
|               |                                                  | <code>`@tf.function`</code>                          |
| Гرادієнти     | неявно, всередині <code>`minimize()`</code>      | явно, через <code>`tf.GradientTape`</code>           |
| Оптимізатор   | <code>`tf.train.GradientDescentOptimizer`</code> | <code>`keras.optimizers.SGD`</code>                  |
| Ініціалізація | <code>`tf.global_variables_initializer()`</code> | автоматична при створенні <code>`tf.Variable`</code> |

Варіант А — низькорівневий TF2 на `tf.GradientTape`. Декоратор `@tf.function` компілює крок навчання у граф, тобто повертає ту саму перевагу, заради якої в TF1 існувала сесія, але без ручної роботи з графом:

```
k = tf.Variable(tf.random.normal((1, 1)), name='slope') # крок 3
b = tf.Variable(tf.zeros((1,)), name='bias')
opt = keras.optimizers.SGD(learning_rate=LEARNING_RATE) # крок 5

@tf.function # компіляція у граф
def train_step(X_batch, y_batch):
    with tf.GradientTape() as tape: # стрічка запису операцій
        y_pred = tf.matmul(X_batch, k) + b # крок 4: модель
        loss = tf.reduce_sum((y_batch - y_pred) ** 2) # крок 4: сума квадратів
        grads = tape.gradient(loss, [k, b]) # автоматичне диференціювання
        opt.apply_gradients(zip(grads, [k, b])) # оновлення k та b
    return loss

for i in range(num_steps): # крок 6
    indices = np.random.choice(n_samples, batch_size)
    loss_val = train_step(tf.gather(X_tf, indices), tf.gather(y_tf, indices))
```

Варіант Б — високорівневий Keras: `Sequential` з одним шаром `Dense(1)`. Шар `Dense` реалізує операцію `output = activation(dot(input, kernel) + bias)`, тобто при `activation=None` його `kernel` — це  $i \in k$ , а `bias` — це  $b$ . Уся модель — 2 параметри, що й підтверджує `model.summary()`. Єдина тонкість: стандартна втрата `'mse'` — це СЕРЕДНЄ по батчу, а не сума, тому її градієнт у `batch_size` разів менший; щоб динаміка навчання збіглася з варіантом А, темп навчання збільшено рівно в `batch_size` разів ( $1 \cdot 10^{-5} \cdot 100 = 1 \cdot 10^{-3}$ ).

Друга тонкість стосується ініціалізації. Рядковий псевдонім `kernel_initializer='random_normal'` у Keras означає не стандартний нормальний розподіл, а `RandomNormal(mean=0.0, stddev=0.05)` — тобто шар стартував би практично з  $k \approx 0$ , а не з того самого розподілу, що й варіанти TF1/TF2, де `tf.random_normal` дає стандартний нормальний. Щоб старт був однаковим, ініціалізатор задано явно, через об'єкт `RandomNormal(stddev=1.0)`. Сам шар `Dense` повертає ваги як два масиви, тому їх ще треба розгорнути у скаляри:

```
model = keras.Sequential([
    keras.layers.Input(shape=(1,)),
    keras.layers.Dense(1,
```

```

        kernel_initializer=keras.initializers.RandomNormal(stddev=1.0),
        bias_initializer='zeros')
], name='linear_regression')
model.compile(optimizer=keras.optimizers.SGD(learning_rate=LEARNING_RATE * batch_size),
              loss='mse')
history = model.fit(X_data, y_data, batch_size=batch_size,
                   epochs=num_steps // (n_samples // batch_size), verbose=0)
w, bias = model.get_weights() # kernel (1,1) i bias (1,)
k_keras, b_keras = float(w.ravel()[0]), float(bias.ravel()[0])

```

TensorFlow: 2.22.0-rc0 | Keras: 3.16.0.dev2026100704 | бекенд Keras: tensorflow  
 Стартове значення k у TF2 (tf.random.set\_seed): -0.8296

Епоха 1: 31356.42968750, k=-0.6214, b=0.0322

Епоха 100: 501.72174072, k=2.0733, b=0.4443

Епоха 4000: 473.04833984, k=2.0431, b=0.6510

Епоха 10000: 274.04394531, k=2.0247, b=0.7182

Епоха 20000: 403.24346924, k=2.0370, b=0.7265

-----  
 TF2 (GradientTape): k = 2.0370, b = 0.7265, час навчання = 3.19 с

Model: "linear\_regression"

| Layer (type)             | Output Shape | Param #             |
|--------------------------|--------------|---------------------|
| dense (Dense)            | (None, 1)    | 2                   |
| Total params: 2 (8.00 B) |              | Trainable params: 2 |

-----  
 Keras Sequential(Dense(1)): k = 2.0304, b = 0.7152, час навчання = 16.96 с (2000 епох)

Остання mse: 4.1335 (mse \* batch\_size = 413.3 -> та сама шкала, що й loss у TF1)

| Реалізація               | k      | b      | час, с |
|--------------------------|--------|--------|--------|
| TF1-compatible (Session) | 2.0370 | 0.7267 | 1.34   |
| TF2 (GradientTape)       | 2.0370 | 0.7265 | 3.19   |
| Keras Sequential(Dense)  | 2.0304 | 0.7152 | 16.96  |
| Аналітичний МНК          | 2.0295 | 0.7158 | -      |
| Істинні параметри        | 2.0000 | 1.0000 | -      |

-----  
 Слід різної початкової ініціалізації k (TF1 проти TF2):

| крок  | різниця  dk | різниця  db |
|-------|-------------|-------------|
| 1     | 0.962602    | 0.011016    |
| 60    | 0.030537    | 0.147063    |
| 100   | 0.022235    | 0.146246    |
| 1000  | 0.016420    | 0.107435    |
| 4000  | 0.005747    | 0.038411    |
| 10000 | 0.000740    | 0.004934    |
| 20000 | 0.000024    | 0.000161    |

Контроль причини розбіжності b у 4-му знаку:

лише тип обчислень (float32 проти float64, однаковий старт): |db| = 8.72e-07

лише початкове k (-1.8647 проти -0.8296, однаковий тип): |db| = 1.61e-04

відтворені значення: b = 0.726708 (старт TF1) проти b = 0.726548 (старт TF2)

=====

## Зведене порівняння результатів:

| Реалізація                               | k      | b      | час навчання, с | відхилення k від МНК | відхилення b від МНК |
|------------------------------------------|--------|--------|-----------------|----------------------|----------------------|
| TF1-compatible ('Session' + 'feed_dict') | 2.0370 | 0.7267 | 1.34            | +0.0075              | +0.0109              |
| TF2 ('GradientTape' + '@tf.function')    | 2.0370 | 0.7265 | 3.19            | +0.0075              | +0.0107              |
| Keras 'Sequential(Dense(1))'             | 2.0304 | 0.7152 | 16.96           | +0.0009              | -0.0006              |
| Аналітичний                              | 2.0295 | 0.7158 | —               | —                    | —                    |

|                              |        |        |   |   |   |
|------------------------------|--------|--------|---|---|---|
| МНК (еталон)                 |        |        |   |   |   |
| Істинні параметри генератора | 2.0000 | 1.0000 | — | — | — |




Рисунок 4 — хмара точок і підігнані прямі всіх трьох реалізацій




Рисунок 5 — спадання функції втрат у TF2 (GradientTape і Keras)

### Завдання 2 (TF2 GradientTape): збіжність $k$ та $b$




Рисунок 6 — збіжність  $k$  та  $b$  у реалізації на *tf.GradientTape*




Рисунок 7 — пряме порівняння TF1-compat і TF2: втрати,  $k$ ,  $b$

На рисунку 7 ліва й середня панелі TF1 і TF2 практично накладаються одна на одну: обидва скрипти використовують одне зерно 3, тому отримують ту саму вибірку даних і ту саму послідовність міні-батчів. Відрізняється лише випадкова початкова ініціалізація  $k$ : TF1 стартує з  $-1.8647$  (`tf.set_random_seed`), TF2 — з  $-0.8296$  (`tf.random.set_seed`); це різні генератори, тому однакове зерно дає різні числа.

Важливо, що цей слід старту згасає в  $k$  і в  $b$  з РІЗНОЮ швидкістю, і права панель рисунка 7 це добре показує: сині й червоні криві коефіцієнта  $b$  помітно розходяться аж приблизно до 10000-го кроку. Скрипт друкує модуль різниці траєкторій напряду:

| крок | модуль різниці по $k$ | модуль різниці по $b$ |
|------|-----------------------|-----------------------|
| 1    | 0.962602              | 0.011016              |
| 60   | 0.030537              | 0.147063              |
| 100  | 0.022235              | 0.146246              |
| 1000 | 0.016420              | 0.107435              |

|       |          |          |
|-------|----------|----------|
| 4000  | 0.005747 | 0.038411 |
| 10000 | 0.000740 | 0.004934 |
| 20000 | 0.000024 | 0.000161 |

Тобто у нахилі  $k$  слід ініціалізації зникає приблизно за 60 ітерацій (різниця падає з 0.96 до 0.03), а у зсуві  $b$  він, навпаки, лише НАРОСТАЄ до 0.147 на 60—100-му кроці й розсмоктується аж до  $\sim 10000$ -го кроку. Причина — та сама пара власних чисел 7620 і 34.3: початкове відхилення по  $k$  майже миттєво гаситься «швидкою» модою, але частина його перекидається у «повільну» моду, яка живе у 222 рази довше і проявляється саме в  $b$ . Тому залишкова розбіжність у четвертому знаку ( $b = 0.7267$  проти  $0.7265$ ) — це не похибка обчислень, а останній хвіст різної початкової ініціалізації. Щоб це не залишалось припущенням, у скрипті зроблено прямий контрольний експеримент: той самий спуск повторено чистим `numpy`, і в ньому окремо змінено або лише тип обчислень, або лише стартове  $k$ . Зміна типу з `float32` на `float64` при однаковому старті зсуває  $b$  лише на  $8.7 \cdot 10^{-7}$ , тобто у шостому знаку, а зміна самого лише стартового  $k$  ( $-1.8647$  проти  $-0.8296$ ) при однаковому типі дає  $b = 0.726708$  проти  $b = 0.726548$ , тобто рівно ті  $0.7267$  і  $0.7265$ , які спостерігаємо. Отже причина — ініціалізація, а не точність накопичення в графовому чи `eager`-режимі.

Щодо часу: найшвидшим виявився статичний граф TF1 (1.34 с), вдвічі повільнішим — `@tf.function` у TF2 (3.19 с, бо на кожній ітерації додається `tf.gather` і зчитування `k.numpy()` для історії), і найповільнішим — високорівневий Keras (16.96 с). Абсолютні значення часу коливаються від запуску до запуску на  $\pm 15\%$ , але співвідношення між реалізаціями стабільне. Відставання Keras не має відношення до математики: на 2 параметри модель витрачає  $\sim 10$  мс на епоху на внутрішню інфраструктуру `fit` (колбеки, `tf.data`-конвеєр, облік метрик). На задачі з двох ваг ця інфраструктура — чиста накладна витрата, але саме вона окупається на реальних мережах.

**Висновок:** усі три реалізації збіглися до одного й того самого розв'язку ( $k \approx 2.03$ ,  $b \approx 0.72$ ), що підтверджує: `tf.GradientTape` і `Dense(1)` виконують ту саму математику, що й граф із `placeholder` та `feed_dict`, а відрізняються лише способом її запису та накладними витратами виконання.

### Звірка власного виводу зі зразком методички

Методичка наводить зразок виводу («Епоха 100: 5962.15625000,  $k=0.8925$ ,  $b=0.0988$ »), але НЕ наводить `learning_rate`, бо викликає

GradientDescentOptimizer() без аргументів. Тому її зразок у принципі не відтворюється однозначно: кожному темпу навчання відповідає своя траєкторія. Наш робочий прогін з  $\text{LEARNING\_RATE} = 1 \cdot 10^{-5}$  дає на 100-й епосі  $\text{loss} = 500.39$  і  $k = 2.0511$  — втрата у 12 разів менша, а нахил уже практично на оптимумі. Щоб показати, що розбіжність спричинена саме темпом навчання, а не іншою математикою, скрипт повторює ТОЙ САМИЙ граф на ТИХ САМИХ даних і з ТИМ САМИМ стартовим  $k$  та тією самою послідовністю міні-батчів, змінюючи лише  $\text{learning\_rate}$ :

```

Підбір темпу навчання під зразок методички (ціль: epoch 100 -> loss 5962.16, k 0.8925):
lr = 5.0e-07 -> епоха 100: loss = 27872.06, k = -0.6186, b = 0.1861
lr = 1.0e-06 -> епоха 100: loss = 13310.46, k = 0.2338, b = 0.3135
lr = 1.5e-06 -> епоха 100: loss = 6482.86, k = 0.8162, b = 0.4006
lr = 2.0e-06 -> епоха 100: loss = 3289.24, k = 1.2134, b = 0.4601
lr = 5.0e-06 -> епоха 100: loss = 529.32, k = 1.9738, b = 0.5755
lr = 1.0e-05 -> епоха 100: loss = 500.39, k = 2.0511, b = 0.5906

```

Отже еталонна траєкторія методички відповідає темпу навчання близько  $1.5 \cdot 10^{-6}$  — приблизно у 7 разів меншому за обраний. Повна звірка по епохах:

| епоха | зразок методички                    | наш прогін, $\text{lr} = 1.5 \cdot 10^{-6}$ | наш прогін, $\text{lr} = 1 \cdot 10^{-5}$ |
|-------|-------------------------------------|---------------------------------------------|-------------------------------------------|
| 100   | 5962.16, $k=0.8925$ ,<br>$b=0.0988$ | 6482.86, $k=0.8162$ ,<br>$b=0.4006$         | 500.39, $k=2.0511$ ,<br>$b=0.5906$        |
| 200   | 5312.12, $k=0.9862$ ,<br>$b=0.1927$ | 1054.58, $k=1.6594$ ,<br>$b=0.5280$         | 402.83, $k=2.0457$ ,<br>$b=0.5981$        |
| 300   | 3904.57, $k=1.0761$ ,<br>$b=0.2825$ | 481.81, $k=1.9293$ ,<br>$b=0.5687$          | 447.97, $k=2.0598$ ,<br>$b=0.6032$        |
| 19900 | 429.80, $k=2.0267$ ,<br>$b=0.9006$  | 453.37, $k=2.0331$ ,<br>$b=0.6731$          | 452.58, $k=2.0172$ ,<br>$b=0.7224$        |
| 20000 | 378.42, $k=2.0179$ ,<br>$b=0.8902$  | 403.31, $k=2.0364$ ,<br>$b=0.6741$          | 403.24, $k=2.0370$ ,<br>$b=0.7267$        |

Звірка зі зразком виводу методички: роль темпу навчання




Рисунок 8 — звірка зі зразком виводу методички: наш прогін ( $lr = 1 \cdot 10^{-5}$ ), контрольний прогін ( $lr = 1.5 \cdot 10^{-6}$ ) і точки зразка методички

На 100-й епосі контрольний прогін збігається зі зразком методички за порядком величини (6482.86 проти 5962.16,  $k = 0.8162$  проти  $0.8925$ ) — це видно на рисунку 8, де перший «хрестик» зразка лежить просто на синій кривій. А от на епохах 200 і 300 збіг зникає: у методички  $k$  зростає лише на  $+0.0937$  і  $+0.0899$  за сотню кроків, тоді як будь-який темп навчання, що дає на 100-й епосі втрату 5962, виводить  $k$  на оптимум уже за наступні 150—200 кроків.

Причина в тому, що сам зразок виводу методички внутрішньо суперечливий. Для  $x \sim U[1; 10]$  градієнт по  $k$  приблизно у 6.6 раза більший за градієнт по  $b$  — скрипт обчислює це співвідношення для точки зразка і друкує 6.57. Отже за однакову кількість кроків  $k$  має зростати приблизно в 6.6 раза швидше за  $b$ . У зразку ж методички прирости  $k$  і  $b$  рівні:  $+0.0937$  проти  $+0.0939$  на епохах  $100 \rightarrow 200$  і  $+0.0899$  проти  $+0.0898$  на епохах  $200 \rightarrow 300$ , тобто співвідношення рівно 1.00. Такої траєкторії градієнтний спуск на цих даних дати не може ні за якого темпу навчання. При цьому самі значення  $loss$  узгоджені з парами  $(k, b)$  бездоганно, а фінальні  $k = 2.0179$ ,  $b = 0.8902$  — цілком правдоподібний оптимум МНК на іншій зашумленій вибірці. Тобто зразок узятий із реального прогону, але стовпчик  $b$  у ньому не належить тому самому прогону, що стовпчики  $loss$  і  $k$ .

Чому все-таки залишено  $LEARNING\_RATE = 1 \cdot 10^{-5}$ , а не «еталонні»  $1.5 \cdot 10^{-6}$ . По-перше, за 20000 кроків обидва темпи приводять до того самого результату, але більший крок робить це за  $\sim 60$  ітерацій замість  $\sim 400$ , тому на рисунках 2, 3 і 8 видно повну картину збіжності. По-друге,  $1 \cdot 10^{-5}$  — це 3.8 % від межі стійкості  $2.62 \cdot 10^{-4}$ , тобто запас надійності більш ніж 25-кратний. По-третє, менший темп не наближає нас до зразка методички по суті: як показано вище, її траєкторія недосяжна в принципі.

### **Чому $b$ зійшлося до 0.72, а не до 1.00**

Окремого пояснення потребує те, що навчене  $b = 0.727$  помітно відрізняється від істинного  $b = 1$ . Це не помилка навчання: градієнтний спуск сходиться не до параметрів генератора, а до оптимуму МНК на конкретній зашумленій вибірці, і цей оптимум для нашої вибірки дорівнює рівно 0.7158 (обчислено незалежно через `np.linalg.lstsq`). Стандартна похибка оцінки зсуву для цих даних становить  $se(b) = 0.154$  (проти  $se(k) = 0.025$  — у 6 разів менше, бо  $x$  змінюється на  $[1; 10]$  і екстраполяція до  $x = 0$  ненадійна). Відхилення  $\hat{b}$  від істинної одиниці

дорівнює  $-1.85$  стандартної похибки, тобто цілком у межах звичайної статистичної флуктуації. Саме тому й у зразку виводу методички `b` зупиняється на  $0.89$ , а не на  $1.00$ .

Залишкова різниця між навченим  $b = 0.7267$  і оптимумом МНК  $0.7158$  — це вже шум самого стохастичного спуску: при сталому `learning_rate` SGD не зупиняється в точці мінімуму, а блукає навколо неї в околі, пропорційному кроку навчання.

## Ресурси Keras (теоретична частина)

Keras — високорівневий фронтенд, який працює поверх бекенду (історично Theano, зараз за замовчуванням TensorFlow). Бекенд перемикається двома способами: правкою поля `"backend"` у конфігураційному файлі `$HOME/.keras/keras.json` (поряд із `image_data_format`, `epsilon`, `floatx`) або змінною оточення `KERAS_BACKEND`. У цій роботі `keras.backend.backend()` повернув `tensorflow`.

Моделі. Основна структура даних Keras — модель, тобто спосіб організації шарів. Є два основні типи: послідовна модель `Sequential` (лінійна сукупність шарів) і клас `Model` функціонального API, що дозволяє будувати довільні графи шарів, у тому числі з кількома входами й виходами: `model = Model(inputs=[a1, a2], outputs=[b1, b2, b3])`.

Спільні властивості й методи моделей: `model.layers`, `model.inputs`, `model.outputs`, `model.summary()`, `model.get_config()`, `model.get_weights()`, `model.set_weights(weights)`, `model.to_json()`. У цій роботі використано `model.summary()` (показав 2 параметри) і `model.get_weights()` (звідти й узято навчені  $k$  та  $b$ ).

Основні методи класу `Model`: `compile(optimizer, loss, metrics, ...)` — налаштування моделі для навчання; `fit(x, y, batch_size, epochs, validation_split, initial_epoch, ...)` — навчання протягом заданої кількості епох; `evaluate(...)` — оцінка якості навченості на тестовому режимі; `predict(x, batch_size, ...)` — створення вихідних прогнозів; `get_layer(name, index)` — отримання шару за іменем або індексом.

Шари. Спільні методи шарів: `layer.get_weights()`, `layer.set_weights(weights)`, `layer.get_config()`; шар відновлюється з конфігурації через `Dense.from_config(config)`. Якщо шар має один вузол, доступні властивості `layer.input`, `layer.output`, `layer.input_shape`, `layer.output_shape`.

Щільний шар `Dense(units, activation=None, use_bias=True, kernel_initializer='glorot_uniform', bias_initializer='zeros', ...)` реалізує операцію `output = activation(dot(input, kernel) + bias)`. Саме цей шар і було застосовано у варіанті Б завдання 2: `Dense(1)` з лінійною активацією — це буквально один нейрон лінійної регресії, що й зазначено в постановці задачі. Для задання активації окремо є `Activation(activation)`.

Перенавчання (overfitting) — модель добре розпізнає лише приклади з навчальної вибірки, втрачаючи здатність до узагальнення. Основний засіб боротьби — метод виключення `Dropout(rate)`: нейрон виключається з мережі з імовірністю `rate`, тобто повертає 0 при будь-яких вхідних даних. Допоміжні шари зміни форми — `Reshape(target_shape)` і `Permute(dims)`.

Ресурси TensorFlow, задіяні в роботі: тензор як основний об'єкт; змінна (`tf.Variable`) як буфер у пам'яті, що вміщує тензори і потребує явної ініціалізації; заглушка `tf.placeholder` для подачі міні-батчів; простори імен змінних (`tf.variable_scope` / `tf.get_variable`) для повторного використання тих самих ваг у різних шляхах обчислень; редукції (`tf.reduce_sum`, `tf.reduce_mean`) і `broadcasting` при поелементних операціях над тензорами різної форми.

### Зауваження до методички

Методичка містить кілька фактичних помилок і застарілих викликів. Нижче — повний перелік знайденого і те, як це обійдено в роботі.

**Зауваження 1. Увесь код написаний під TensorFlow 1.x.** `tf.placeholder`, `tf.Session`, `feed_dict`, `tf.train.GradientDescentOptimizer`, `tf.variable_scope`, `tf.random_normal` — жодного з цих імен немає в кореновому просторі імен встановленого TensorFlow 2.22. Обійдено: перший скрипт імпортує `tensorflow.compat.v1 as tf` і викликає `tf.disable_v2_behavior()`, завдяки чому код працює дослівно; другий скрипт показує сучасний еквівалент.

**Зауваження 2. `tf.initialize_global_variables()` не існує.** Правильна назва — `tf.global_variables_initializer()`. Виклик із методички негайно падає з `AttributeError`. виправлено в коді; в коментарі зазначено оригінал.

**Зауваження 3. `tf.mul` застаріло.** У теоретичному прикладі з `feed_dict` використано `output = tf.mul(x, y)`. Ця функція вилучена ще в TF 1.0; сучасна назва — `tf.multiply` (у TF2 — `tf.math.multiply`). Перевірено: `hasattr(tf, 'mul')` повертає `False`.

**Зауваження 4. `GradientDescentOptimizer()` викликано без обов'язкового `learning_rate`.** У методичці стоїть

`tf.train.GradientDescentOptimizer().minimize(loss)`, що падає з `TypeError: missing 1 required positional argument: 'learning_rate'`. Темп навчання довелося підібрати самостійно: обчислено межу стійкості для цих даних ( $2.62 \cdot 10^{-4}$ ) і обрано  $\text{LEARNING\_RATE} = 1 \cdot 10^{-5}$  — 3.8 % від межі. Наслідок цього пропуску важливіший, ніж просто падіння коду: без `learning_rate` зразок виводу методички взагалі не є відтворюваним. Скануванням темпу навчання (розділ «Звірка власного виводу зі зразком методички») встановлено, що еталонна траєкторія методички відповідає  $\text{lr} \approx 1.5 \cdot 10^{-6}$ , тобто приблизно у 7 разів меншому кроку; з обраним  $1 \cdot 10^{-5}$  на 100-й епосі виходить  $\text{loss} = 500.39$ ,  $k = 2.0511$  замість  $5962.16 / 0.8925$ . Розбіжність свідомо й пояснена, а не випадкова.

**Зауваження 5. Суперечність між текстом і кодом щодо інтервалу  $x$ .** Текст методички (пункт 1 алгоритму) каже «1000 випадкових точок рівномірно на інтервалі  $[0; 1]$ », а код генерує `np.random.uniform(1, 10, ...)`, тобто  $[1; 10]$ . Взято код, і вирішальний аргумент тут один: наведений методичкою зразок виводу на інтервалі  $[0; 1]$  неможливий. У стані зі зразка ( $k = 0.8925$ ,  $b = 0.0988$ ) очікувана втрата на міні-батчі зі 100 точок дорівнює 6047 на  $[1; 10]$  і лише 608 на  $[0; 1]$ , а методичка друкує 5962.16. Самі інтервали відрізняються за дисперсією  $x$  рівно у 81 раз (емпірично 6.5313 проти 0.0806) і у 111 разів за  $E[x^2]$  (37.2723 проти 0.3356). Зауважимо окремо, що на  $[0; 1]$  задача не стає нерозв'язною — навпаки, вона краще обумовлена: власні числа матриці кроку там 254.44 і 12.68 проти 7620.18 і 34.28, а межа стійкості  $7.86 \cdot 10^{-3}$ , тобто у 30 разів БІЛЬША. З тим самим  $\text{lr} = 1 \cdot 10^{-5}$  за 20000 кроків на  $[0; 1]$  виходить  $k = 2.0261$ ,  $b = 0.8773$  при МНК-оптимумі  $2.2653 / 0.7453$  (збіжність часткова), а з  $\text{lr} = 1 \cdot 10^{-3}$  спуск збігається повністю ( $k = 2.2804$ ,  $b = 0.6472$ ). Отже обмеження тут не фундаментальне, а наслідок фіксованого темпу навчання.

**Зауваження 6. Плутанина «дисперсія/стандартне відхилення» в описі шуму.** Текст каже «шум із дисперсією 2,  $\epsilon \sim N(\epsilon; 0, 2)$ », але в коді стоїть `np.random.normal(0, 2, ...)`, де другий аргумент NumPy — це стандартне відхилення, а не дисперсія. Отже, фактично  $\sigma = 2$ , дисперсія = 4. Це видно і з самої методички: наведена нею фінальна помилка 378 відповідає межі  $\text{batch} \cdot \sigma^2 = 100 \cdot 4 = 400$ , а не  $100 \cdot 2 = 200$ . У роботі використано код ( $\sigma = 2$ ) і перевірено збіг із цією межею (отримано 403.2).

**Зауваження 7. `loss` у прикладі — сума, а не середнє.** Через `tf.reduce_sum` функція втрат масштабується разом із розміром батча, тому її абсолютні значення великі (тисячі й десятки тисяч) і на око «не схожі на помилку». Це також означає, що градієнт у 100 разів більший за градієнт середньоквадратичної похибки, і стандартні значення `learning_rate` (0.01, 0.001) тут миттєво розбігаються. У роботі цю властивість враховано явно: при переході на Keras із `loss='mse'` темп навчання збільшено рівно в `batch_size` разів, щоб динаміка збіглася.

**Зауваження 8. `print('%0.4f' % k_val)` падає в сучасному NumPy.** Змінна `k` має форму (1, 1), `b` — форму (1,), а з NumPy 1.25 неявне перетворення непустиго масиву на скаляр є помилкою (`TypeError: only 0-dimensional arrays can be converted to Python scalars`). Виправлено явним `float(np.ravel(k_val)[0])`.

**Зауваження 9. Крок друку 100 ховає найцікавішу частину навчання.** Основне спадання функції втрат (з 56663 до ~500) відбувається за перші ~60 ітерацій, тобто повністю потрапляє в проміжок до першого ж друку. Сам друк залишено таким, як у методичці — рівно кожні 100 епох, 200 рядків; у звіт із них винесено лише скорочений витяг. Натомість історію в скрипті записуємо на КОЖНОМУ кроці, на рисунках 2, 3, 5, 6 додано окрему панель зі стартом навчання, а у вивід додано (понад методичку) перші 5 кроків.

**Зауваження 10. Некоректне посилання в постановці завдання.** Методичка пропонує «використовувати онлайн-середовище `google-colab` (перехід за посиланням: <http://neuralnetworksanddeeplearning.com/chap4.html>)». За цим посиланням розташована глава книги Майкла Нільсена про універсальну апроксимацію, а не Google Colab. Роботу виконано локально у віртуальному оточенні `/Users/alex/.venvs/systems-ai`.

**Зауваження 11. Зразок виводу методички внутрішньо суперечливий.** У наведеному методичкою прикладі стовпчики `k` і `b` зростають з однаковою швидкістю: +0.0937 проти +0.0939 на епохах 100 → 200 і +0.0899 проти +0.0898 на епохах 200 → 300, тобто співвідношення приростів рівно 1.00. Але для  $x \sim U[1; 10]$  градієнт функції втрат по `k` приблизно у 6.6 раза більший за градієнт по `b` (обчислено в скрипті для точки зразка: 6.57), тому `k` зобов'язане зростати у ~6.6 раза швидше. Градієнтний спуск на цих даних не може дати траєкторію з рівними приростами ні за якого темпу навчання. Значення `loss` при цьому бездоганно узгоджені з парами (`k`, `b`), а фінальні `k` = 2.0179 і `b` = 0.8902 правдоподібні як оптимум МНК на іншій вибірці. Висновок: зразок узято з реального прогону, але стовпчик `b` у ньому не належить тому самому прогону, що `loss` і `k`. Саме тому в

розділі «Звірка власного виводу зі зразком методички» порівняння доведено лише до 100-ї епохи, де воно ще має сенс.

**Зауваження 12. Розбіжність у нумерації.** Файл методички названий «ЛР 8», а всередині заголовок — «Лабораторна робота №10». У звіті використано нумерацію 8.

## Висновки

У роботі досліджено структуру розрахункового алгоритму навчання лінійної регресії засобами TensorFlow і реалізовано його у двох варіантах. Перший скрипт (LR\_8\_task\_1\_tf1\_compat.py) дослівно відтворює код методички через шар сумісності tensorflow.compat.v1 зі статичним графом, сесією та feed\_dict. Другий (LR\_8\_task\_2\_tf2.py) розв'язує ту саму задачу сучасними засобами TensorFlow 2.22 — через tf.GradientTape із декоратором @tf.function, а також через високорівневу модель keras.Sequential з єдиним шаром Dense(1). Обидва скрипти реально запущені; усі наведені числа є фактичним виводом консолі.

Алгоритм із шести кроків методички працює як задумано. Функція втрат спадає з 56663 на першій ітерації до  $\sim 403$  наприкінці навчання, тобто падає більш ніж у 140 разів і виходить на теоретичну межу  $\text{batch} \cdot \sigma^2 = 100 \cdot 2^2 = 400$  — нижче цієї межі функція втрат опуститися не може в принципі, бо вона дорівнює сумі квадратів самого шуму, який у даних є непереборним. Коефіцієнти збіглися до  $k = 2.0370$  і  $b = 0.7267$  у TF1-реалізації та до  $k = 2.0370$ ,  $b = 0.7265$  у TF2-реалізації; високорівневий Keras дав  $k = 2.0304$  і  $b = 0.7152$ .

Усі три реалізації збіглися до одного й того самого розв'язку, причому цей розв'язок — не параметри генератора ( $k = 2$ ,  $b = 1$ ), а оптимум методу найменших квадратів на конкретній зашумленій вибірці, незалежно обчислений через `np.linalg.lstsq` і рівний  $k = 2.0295$ ,  $b = 0.7158$ . Відхилення навченого  $b$  від одиниці пояснюється статистикою, а не помилкою оптимізації: стандартна похибка оцінки зсуву на цих даних становить 0.154, тобто отримане значення лежить за 1.85 стандартної похибки від істинного. Саме з цієї ж причини і в зразку виводу методички  $b$  зупиняється на 0.89. Залишкова різниця між навченим  $b = 0.7267$  та оптимумом 0.7158 — це стаціонарний шум SGD зі сталим кроком навчання.

Дослідження структури алгоритму виявило його найважливішу особливість: збіжність розпадається на два режими з різними швидкостями. Матриця одного кроку спуску для цих даних має власні числа 7620.18 і 34.28, що відрізняються в

222 рази. «Швидкий» режим виводить нахил  $k$  на оптимум уже за  $\sim 60$  ітерацій, тоді як «повільний» режим відповідає за зсув  $b$  і розтягує навчання на всі 20000 кроків. Саме це число обумовлення (а не складність задачі з двох параметрів) і пояснює, навіщо методичці знадобилося 20000 ітерацій на підгонку прямої. Той самий поділ на дві моди пояснює і розбіжність між двома реалізаціями: різне стартове  $k$  ( $-1.8647$  у TF1 проти  $-0.8296$  у TF2) зникає з коефіцієнта  $k$  за  $\sim 60$  ітерацій, але в коефіцієнті  $b$  тягнеться приблизно до 10000-го кроку, що добре видно на правій панелі рисунка 7.

Окремо звірено власний вивід зі зразком, наведеним у методичці. Оскільки `learning_rate` у методичці не заданий, її зразок не є однозначно відтворюваним; скануванням темпу навчання встановлено, що еталонна траєкторія відповідає  $lr \approx 1.5 \cdot 10^{-6}$  — приблизно у 7 разів меншому кроку, ніж обраний  $1 \cdot 10^{-5}$ . Саме через це на 100-й епосі власний прогін дає `loss` = 500.39 і  $k$  = 2.0511 замість 5962.16 і 0.8925. При цьому точне відтворення зразка неможливе в принципі: у ньому коефіцієнти  $k$  і  $b$  зростають з однаковою швидкістю, тоді як на даних з інтервалу  $[1; 10]$  градієнт по  $k$  у 6.57 разів більший за градієнт по  $b$ , тож  $k$  зобов'язане випереджати  $b$  приблизно в 6.6 разів.

Порівняння реалізацій за швидкістю дало очікуваний результат: статичний граф TF1 виявився найшвидшим (1.34 с), `@tf.function` у TF2 — 3.19 с, а високорівневий `model.fit` Keras — 16.96 с. Різниця не пов'язана з математикою: на моделі з двох параметрів інфраструктура `fit` (колбеки, конвеєр `tf.data`, облік метрик) стає домінуючою накладною витратою. Практичний висновок такий: для навчальних задач такого масштабу низькорівневий `tf.GradientTape` і зрозуміліший, і швидший, тоді як переваги Keras проявляються на реальних багатоварових мережах, де ручне керування градієнтами перетворюється на джерело помилок. Водночас реалізація на `tf.GradientTape` є прямим і повністю еквівалентним заміником застарілої схеми `placeholder + Session + feed_dict`, тож код методички не втратив навчальної цінності — його потрібно лише перекласти на сучасний API.